

DATA SCIENCE

Conteúdo Programático

Prof. Gabriel Resende Machado

 gabrielmachado@unifeso.edu.br

 <https://www.linkedin.com/in/machadogabriel>

 <https://github.com/UNIFESO-Gabriel/data-science>

Professor: Gabriel Resende Machado



- **Formação:**

- **Mestre:** Sistemas e Computação (IME, 2019);
- **Bacharel:** Ciência da Computação (UNIFESO, 2016).

- **Áreas de Especialização:**

- Ciência de Dados;
- Banco de Dados;
- Algoritmos.

- **Principais formas de contato:**

- E-mail e LinkedIn (disponíveis no *slide* de capa);
- Plataforma Canvas (plano de aula, ementa, *slides* de aulas, tarefas e exercícios).

Sobre a Disciplina

- **Objetivos gerais:**

- Estimular a compreensão de como a Ciência de Dados pode ser útil para a construção de soluções de apoio à decisão, envolvendo desde as etapas de preparação e extração dos dados até a análise e visualização;
- Promover o aprendizado de técnicas e algoritmos mais comuns da área de Ciência de Dados, possibilitando sua aplicação em problemas do mundo real.


- **Planejamento** (arquivos disponíveis no Canvas):

- **Plano de Ensino:** <https://bit.ly/4dnchYE>;
- **Plano de Curso:** <https://shorturl.at/uxD78>.

Avaliações

- **Avaliação 1 (AV1):**
 - **Qstione** (previsto para 30/09/24): **40 pontos**;
 - **Projeto 1** (entrega prevista para 30/09/24 via Canvas): **60 pontos**.
- **Avaliação 2 (AV2):**
 - **Qstione** (previsto para 02/12/24): **40 pontos**;
 - **Projeto 2** (entrega prevista para 02/12/24 via Canvas): **60 pontos**
- Ambas as avaliações do Qstione serão compostas por 10 questões objetivas e 02 discursivas;
- As avaliações do Qstione compõem 40% da nota trimestral. 60% restantes vêm de trabalhos e/ou atividades.

Cômputo da nota final



- **Avaliações especiais:**

- **2ª chamada (09/12/24):** somente para alunos que faltaram **em uma** das avaliações do Qstione.
- **Reavaliação (16/12/24):** somente para os alunos com a nota final presente no intervalo [40, 60).

* Frequência abaixo dos 75% das aulas resulta em **reprovação por faltas**;

** A prova de reavaliação compreende toda a matéria do curso e é elaborada livremente pelo professor.

DATA SCIENCE

AULA 1 - Introdução

Prof. Gabriel Resende Machado



gabrielmachado@unifeso.edu.br




<https://www.linkedin.com/in/machadogabriel>



<https://github.com/UNIFESO-Gabriel/data-science>

Dados: o ouro do Século XXI

Volume of data created, captured, copied and consumed worldwide from 2010 to 2025



Disponível em <https://shorturl.at/wU248>.

- De acordo com <https://shorturl.at/aGMPR>, em 2019, por dia, em média:

- 500 milhões de *tweets* foram postados;
- 294 bilhões de *emails* foram enviados;
- 95 milhões de fotos foram compartilhadas no *Instagram*;
- 5 bilhões de buscas foram realizadas, sendo 3,5 bilhões no *Google*;
- 4 *petabytes* de dados foram criados pelo *Facebook*.

Abreviação	Unidade	Valor
b	bit	0 or 1
B	bytes	8 bits
KB	kilobytes	1,000 bytes
MB	megabyte	1,000 ² bytes
GB	gigabyte	1,000 ³ bytes
TB	terabyte	1,000 ⁴ bytes
PB	petabyte	1,000 ⁵ bytes
EB	exabyte	1,000 ⁶ bytes
ZB	zettabyte	1,000 ⁷ bytes
YB	yottabyte	1,000 ⁸ bytes



1 ZB equivale a
1.073.741.824 HDs

A era do *Big Data*




Adaptado de <https://shorturl.at/bdWZ2>.

- Dados produzidos a partir do aumento da digitalização e de avanços tecnológicos em diversos setores;
- * Se dividem principalmente em dados (i) estruturados, (ii) semi-estruturados e (iii) desestruturados.

Mas afinal, o que é Ciência de Dados?

- A Ciência de Dados envolve princípios, processos e técnicas para a compreensão de fenômenos a partir da **análise automatizada** de dados. [1, p. 4];
- O papel da Ciência de Dados é **transformar** grandes quantidades de dados, que as empresas coletam diariamente, em **informações** compreensíveis e úteis por meio de Análise Estatística e do uso de técnicas de **Inteligência Artificial (IA)**, como o **Aprendizado de Máquina (AM)** [2].



Disponível em <https://shorturl.at/wyEGL>.

[1] PROVOST, Foster; FAWCETT, Tom. Data Science for Business: What you need to know about data mining and data-analytic thinking." O'Reilly Media, Inc.", 2013.


[2] Adaptado de <https://shorturl.at/pyXY6>.

Definição de Ciência de Dados

- Campo **interdisciplinar** que utiliza métodos, processos, algoritmos e sistemas para **extrair conhecimentos e *insights* a partir de dados** estruturados, semi-estruturados e desestruturados;
- Combina técnicas de **estatística, aprendizado de máquina, análise de dados e programação para resolver problemas complexos e ajudar em tomadas de decisão que podem afetar todo um ecossistema de uma empresa;**
- Obviamente, a Ciência de Dados necessita de dados como matéria-prima para resolver problemas de negócio de empresas de qualquer segmento.

Os pilares da Ciência de Dados

- Basicamente, a Ciência de Dados envolve o uso de **métodos automatizados (Ciência da Computação)** para **analisar (Matemática e Estatística)** enormes quantidades de dados, a fim de **extrair conhecimento (Conhecimento de Negócio)** a partir desses dados. Por fim, esse conhecimento é **transmitido a partir de ferramentas e processos de visualização (Comunicação e Visualização)**.



Os Pilares da Ciência de Dados em Detalhes



Dados e Tomada de Decisão



- **Problema identificado:** os clientes cancelam seus planos de telefonia com frequência entre 2 a 3 meses após a assinatura do plano;
- 1. **Dados e Análise:** Dados coletados e analisados levaram à conclusão que existe uma tendência entre os clientes trocarem de operadora após o terceiro contato com o atendimento;
- 2. **Decisão:** Os executivos da empresa decidiram, baseados nas análises, rever todos os processos de atendimento ao cliente;
- 3. **Ação:** A empresa contratou uma consultoria para fornecer treinamento especializado ao atendimento ao cliente.

O Processo *Data-Driven*



Dados e Tomada de Decisão



- **Problema identificado:** os clientes cancelam seus planos de telefonia com frequência entre 2 a 3 meses após a assinatura do plano;
- 1. **Dados e Análise:** Dados coletados e analisados levaram à conclusão que existe uma tendência entre os clientes trocarem de operadora após o terceiro contato com o atendimento;
- 2. **Decisão:** Os executivos da empresa decidiram, baseados nas análises, rever todos os processos de atendimento ao cliente;
- 3. **Ação:** A empresa contratou uma consultoria para fornecer treinamento especializado ao atendimento ao cliente.


Ética em Ciência de Dados

- **Responsabilidade e Transparência:** deve haver transparência sobre os métodos de utilização dos algoritmos e dados, por meio de documentações e justificativas claras;
- **Justiça e Não Discriminação:** dados enviesados devem ser evitados para que não sejam criados modelos que possam levar a decisões injustas ou discriminatórias;
- **Consentimento Informado:** os indivíduos devem ser informados, de forma clara e compreensível, sobre como seus dados serão usados e prover consentimento explícito para a coleta e utilização desses dados;
- **Beneficência e Não Maleficência:** é preciso garantir que as análises tragam benefícios e evitem causar danos aos indivíduos ou grupos envolvidos. Para isso, deve ser considerados os impactos sociais éticos das análises e decisões baseadas em dados.

Privacidade em Ciência de Dados

- **Proteção de Dados Pessoais:** dados devem ser protegidos contra acessos não autorizados, vazamentos e outros riscos de segurança;
- **Conformidade com Regulamentações:** regulamentos sobre proteção e privacidade de dados devem ser cumpridas, como o **Regulamento Geral de Proteção de Dados (GDPR)**, na Europa, e a **Lei de Proteção de Dados (LGPD)**, no Brasil. Essas leis estabelecem diretrizes sobre coleta, processamento, armazenamento e compartilhamento de dados pessoais;
- **Minimização de Dados:** apenas os dados necessários para uma análise específica devem ser coletados e armazenados;
- **Direitos dos Titulares dos Dados:** os responsáveis pela produção dos seus dados individuais devem ter o direito de acessá-los, corrigi-los ou alterá-los de forma fácil.

Hierarquia de *jobs* na área de dados



Disponível em <https://shorturl.at/mEMN4>.

A necessidade por Cientistas de Dados

Data Scientist: A Hot Job That Pays Well

Since December 2013, data science postings have rocketed 256%—more than tripling. Houston, San Francisco offer the best salaries for data scientists.

By [Andrew Flowers](#) January 17, 2019

Back in 2012, the Harvard Business Review called data scientist “[the sexiest job of the 21st Century](#).” Six years later, the job has only grown sexier. More employers than ever are looking to hire these skilled digital data jockeys. And while interest from job seekers is growing, Indeed research shows job postings are growing even faster. There may not be enough skilled applicants, so bargaining power in this explosively-growing data scientist job market likely remains with job seekers.

Job postings statistics tell the story. Data scientist postings as a share of all postings on Indeed jumped a full 31% in December 2018, compared with the same period the year before. Yet, that was just another solid year in the spectacular and steady rise in data science jobs on Indeed. Since December 2013, postings have rocketed 256%—more than tripling.

Why is this job growing like gangbusters? It's because employers use data scientists to solve all sorts of problems. In essence, data scientists are tasked to take raw data and use programming, visualization, and statistical modeling to extract insights, [according to the Bureau of Labor Statistics](#) (BLS).

Data scientists are in high demand

Data scientist job postings, per 1 million postings on Indeed



Disponível em <https://shorturl.at/vwLMN>.



Olhar Digital > Pro > Levantamento mostra aumento de mais de 450% nas vagas para cientistas de dados

PRO


Levantamento mostra aumento de mais de 450% nas vagas para cientistas de dados

Lauro Lam | 24/06/2021 13h42




Disponível em <https://shorturl.at/eixW5>.

Ferramentas utilizadas ao longo do curso




Sobre o *Python* I

- Linguagem multiparadigma, interpretada e dinamicamente tipada;
- Desenvolvida a partir das linguagens C/C++;
- Conhecida por sua sintaxe amigável e de “fácil aprendizado”;
- Versátil e multifuncional: possui grande variedade de pacotes que estendem suas funcionalidades;
- Principal linguagem utilizada em projetos relacionados à *Data Science*.



Sobre o *Python* II

- Nem tudo são flores: *Python* é uma linguagem conhecida também pela **sua lentidão**;
- Versões mais recentes do *Python* vêm tentando otimizar o interpretador, diminuindo o tempo de execução do código;
- Devido à lentidão, outras linguagens no ramo de *Data Science* podem ser adotadas, como *Julia* e *Go*;
 - Vale ressaltar aqui o surgimento da linguagem *Mojo**, um possível sucessor do *Python* a médio-longo prazo.



Mojo 




* <https://www.modular.com/mojo>.

Python: Boas práticas de programação

“Any fool can write code that a computer can understand. Good programmers write code that humans can understand.” – Martin Fowler

- **Tenha empatia:** pratique a escrita de um código legível, documentado e manutenível. No futuro, alguém irá te agradecer, incluindo você mesmo!
- **For loops devem ser evitados ao máximo.** Use as funções *built-in* do *Python* e de suas bibliotecas;
- Leia a documentação oficial do Python de boas práticas: PEP 8*;
- Leia livros e consuma materiais que auxiliem nas boas práticas de programação. Cientistas de Dados também são programadores!

* <https://peps.python.org/pep-0008>.



Python - Overview da Linguagem

DATA SCIENCE

AULA 1 - Introdução **Duvidas e/ou perguntas?**



gabrielmachado@unifeso.edu.br



<https://www.linkedin.com/in/machadogabriel>



<https://github.com/UNIFESO-Gabriel/data-science>