

DATA SCIENCE

AULA 2 - Análise Exploratória

Prof. Gabriel Resende Machado



gabrielmachado@unifeso.edu.com




<https://www.linkedin.com/in/machadogabriel>



<https://github.com/UNIFESO-Gabriel/data-science>

O que é a Exploração dos Dados (EDA)?

- Etapa **crucial** que antecede qualquer tarefa que envolva Ciência de Dados;
- Ajuda na **compreensão dos dados**, seu **contexto**, **principais atributos** e suas **características**;
- Contribui na **detecção de padrões e anomalias**;
- Auxilia na **seleção de atributos** e na **geração de modelos preditivos**.



Adaptado de <https://shorturl.at/iJPT6>.

Ferramentas para EDA

- **Estatística Descritiva:**
 - **Medidas de tendência central:** média, mediana e moda;
 - **Medidas de posição:** quantis, quartis e percentis.
 - **Medidas de dispersão:** variância, desvio padrão, IQR;
 - **Medidas de distribuição:** momento;
 - **Medidas de relação:** covariância e correlação.
- **Visualização dos atributos:**
 - Histogramas;
 - *Boxplots*;
 - *Kernel Density Estimation* (KDE).
 - *Scatter plots*;

Estatística Descritiva - Tendência Central

- Definem **pontos centrais** de referência em análise de **dados univariados** (apenas um atributo);
- Define-se um conjunto de valores para um atributo $x^j = \{x_1, x_2, \dots, x_n\}$;
 - **Média:** ponto central calculado a partir da equação $\mu_{x^j} = \frac{1}{n} \sum_{i=1}^n x_i$;
 - A média pode ser representada também por $\bar{x}$ ou $E(x)$;
 - É suscetível a valores extremos (*outliers*);
 - **Mediana:** alternativa à média, por ser uma estatística mais robusta a *outliers*;
 - A partir de um conjunto ordenado de forma crescente, calcula-se:
$$med(x^j) = \begin{cases} \frac{1}{2}(x_r + x_{r+1}) & \text{se } n \text{ for par } (n = 2r) \\ x_{r+1} & \text{se } n \text{ for ímpar } (n = 2r + 1) \end{cases}$$
 - **Moda:** mais voltada a valores categóricos, calcula o valor com maior ocorrência.

Estatística Descritiva - Tendência Central

- Variações da média para cálculo de tendências centrais:
 - **Média ponderada:** calculada a partir de pesos atribuídos aos valores de w^j a partir de x^j :

$$\mu_{x_j, w_j} = \sum_{i=1}^j \frac{w_i x_i}{w_i}$$

- **Média harmônica:** ideal para cálculo de medidas inversamente proporcionais (*e.g.* velocidade/tempo, *F1-score*).


$$H_{x_j} = \sum_{i=1}^n \frac{1}{\frac{1}{x_1} + \frac{1}{x_2} + \dots + \frac{1}{x_n}} = \frac{1}{\sum_{i=1}^n \frac{1}{x_i}}$$

Estatística Descritiva - Posição

- Se caracterizam pelas estatísticas de **quantis**, **quartis** e **percentis** em sequências de dados **ordenados de forma crescente**;
- **Quantil** é um termo mais geral utilizado para descrever divisões de dados em n partes iguais;
- **Quartis** repartem o conjunto de dados em quatro partes de tamanhos aproximadamente iguais. *E.g.*, o valor $Q(1)$ de uma sequência possui 25% dos valores abaixo dele;
- **Percentis** são semelhantes aos quartis, contudo dividem a sequência de dados em 100 partes, ao invés de apenas 4;
- A **mediana** pode ser calculada a partir do quartil $Q(2)$ ou pelo percentil $P(50)$.

Estatística Descritiva - Dispersão I


- Tem como objetivo calcular o **nível de dispersão** dos dados no entorno de uma medida de tendência central;
- As estatísticas mais utilizadas são a variância $S^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$ e o desvio padrão $\sigma = \sqrt{S^2}$;
- O desvio padrão é comumente mais adotado por estar na mesma escala dos dados.



Função densidade de probabilidade (PDF) $N(\mu=0, \sigma=1)$.

Estatística Descritiva - Dispersão II

- **IQR (*Interquartile Range*)**: mede a dispersão dos dados em torno da tendência central;
 - Basicamente, $IQR = Q(3) - Q(1)$.




Estatística Descritiva - Distribuição


- As medidas que são definidas em torno da média de um conjunto de valores são, em sua maioria, oriundas de instâncias de uma estatística chamada **momento**.

$$momento_{k>2}(x^j) = \frac{\sum_{i=1}^n (x_i - \mu_{x^j})^k}{n * \sigma^k}$$

- Quando $k = 1$, considera-se a média como primeiro momento central;
- Quando $k = 2$, considera-se a variância como segundo momento central;
- Quando $k = 3$, **obliquidade** (*skewness*). Mede a simetria em torno da média:
 - obliquidade = 0: aproximadamente simétrica;
 - obliquidade > 0: a distribuição se concentra mais à esquerda;
 - obliquidade < 0: a distribuição se concentra mais à direita;
- Quando $k = 4$, **curtose** (*kurtosis*), representa o achatamento da PDF:
 - curtose = 0: achatamento aprox. de uma distribuição normal;
 - curtose > 0: menor achatamento em comparação com a distr. normal;
 - curtose < 0: maior achatamento em comparação com a distr. normal.



Diferentes obliquidades.



Diferentes curtoses.


Estatística Descritiva - Relação

- Tem como objetivo calcular o **nível de relacionamento** ou **dependência multivariada**;
- As estatísticas mais utilizadas são **covariância, correlação de Pearson e correlação de Spearman**;

- A covariância $Cov(x, y) = \frac{\sum_{i=1}^n (x_i - \mu_{xj})(y_i - \mu_{yj})}{n}$ mede o grau com que os atributos variam juntos, considerando uma relação linear. Contudo, a correlação de Pearson é utilizada com mais frequência por definir os valores possíveis em um intervalo de $[-1, 1]$.
- Dentre os valores que a correlação de Pearson $Corr(x, y) = \frac{Cov(x, y)}{\sigma_x \sigma_y}$ pode assumir, há três valores relevantes:
 - **$Corr(x, y) = 0$** : não há um relacionamento linear;
 - **$Corr(x, y) = 1$** : presença de relacionamento linear positivo diretamente proporcional (e.g. peso e altura);
 - **$Corr(x, y) = -1$** : presença de relacionamento linear negativo inversamente proporcional (e.g. oferta e demanda);

Estatística Descritiva - Visualização

- **Histogramas:** organizam os dados em grupos chamados ***bins***, como forma de visualização da distribuição dos dados;
- É importante frisar que um histograma **não é** um gráfico tradicional de colunas.
- Exemplo de histograma para a sequência {10, 20, 20, 30, 40, 50, 60, 100, 250, 400, 600}:



Estatística Descritiva - Visualização

- **boxplots:** apresentam uma outra visão da distribuição dos dados, desta vez utilizando as estatísticas referentes aos quartis $Q(1)$, $Q(2)$ (mediana) e $Q(3)$.
- **outliers:** valores extremos representados por pontos, definidos a partir das fórmulas definidas abaixo. Existem variações mais “conservadoras” de *boxplots* para a definição de *outliers*.





Imagem adaptada de <https://shorturl.at/amyIK>.


Estatística Descritiva - Visualização

- **KDE (Kernel Density Estimation):** mostram a densidade dos pontos de um conjunto de dados;
 - Essas visualizações ajudam a estimar aproximadamente se os dados seguem alguma distribuição estatística a partir da concentração dos seus pontos.
 - Exemplo de KDE para a sequência {10, 20, 20, 30, 40, 50, 60, 100, 250, 400, 600}:



Estatística Descritiva - Visualização

- **Scatter plots:** mostram a relação dos pontos entre dois atributos de um conjunto de dados;
 - Essas visualizações também ajudam a visualizar correlações entre os dados a partir da concentração dos seus pontos.



Exercício EDA - Pokémon Dataset

- **Dados disponíveis em:** <https://www.kaggle.com/datasets/abcsds/pokemon>;
- **Realizar as seguintes tarefas:**
 - Explore os atributos do dataset e procure por valores nulos e duplicados;
 - Qual o tipo de pokémon mais presente no dataset? (considere as duas colunas para isso);
 - Exiba em um gráfico a quantidade de pokémons por tipo (considere as duas colunas para isso);
 - Liste os 10 pokémons mais poderosos a partir de uma medida de agregação;
 - Liste os pokémons mais poderosos por tipo (considere as duas colunas para isso);
 - Os pokémons lendários são, em média, mais fortes ou mais fracos que os pokémons normais?
 - Liste, por categoria, a média das habilidades dos pokémons.

DATA SCIENCE

AULA 2 - Introdução **Duvidas e/ou perguntas?**



gabrielmachado@unifeso.edu.com



<https://www.linkedin.com/in/machadogabriel>



<https://github.com/UNIFESO-Gabriel/data-science>